EXPERT WORK · 测评报告 · 2026.10

Expert Work

同一个模型做表格任务，与第 1 名几乎持平

测评集 SpreadsheetBench（中国人民大学、清华大学与智谱 AI 发布）· 50 道真实表格处理题 · 5 家统一使用 DeepSeek V4.1 Flash 模型

84.3% 答对率 · 2 轮平均	**< 1 道题** 与第 1 名 Pi 的差距	**¥0.18** 每道题的模型费用，5 家居中

RANKING · 5 家同题同模型

答对率排名：Expert Work 第 2，与第 1 名相差不到 1 道题

答对 = 答案区域的每一格都与标准答案一致 · Expert Work 为 2 轮平均（84.8% / 83.7%），其他 4 家为 HarnessRouter 公布的 1 轮成绩 · 条形从 70% 画起

排名	框架	答对率
1	Pi OpenClaw 等热门智能体的底层框架	85.1%
2	**Expert Work** 2 轮平均	**84.3%**
3	OpenCode	81.3%
4	DeepSeek Harness	78.3%
5	Cline	76.6%

橙色 = Expert Work · 50 道题里，相邻两名的差距都不到 2 道题

01 · 意义

这对 Expert Work 意味着什么

同档

表格处理能力不吃亏

对手是 4 个热门的开源智能体框架，第 1 名 Pi 是 OpenClaw 等热门智能体的底层框架。同一个模型下，Expert Work 与它几乎持平，高于另外 3 家。

2 个测评集

结论一致

综合工作任务（Harness-Bench）和表格处理（SpreadsheetBench）两项测评中，Expert Work 都排第 2，与第 1 名同档。

¥0.18

成本居中

每道题约 0.18 元，比最贵的 Cline 省三成，比最省的 Pi 多三成左右。

02 · 技术可解释性

Expert Work 做对了什么

逐题对照 5 家的判分结果和执行记录后，有数据支撑的两点

做同样的题，步骤最少

做完同样 50 道题，Expert Work 调用工具约 486 次（2 轮平均），另外 4 家要 582–833 次。

486

对方 582–833 次

错的大多是公认的难题

2 轮共错 14 题次，其中 11 题次是另外 4 家也全部做错的题。

11 / 14

错题里 4 家也全错的

03 · 成本

每道题约 0.18 元，5 家居中

按同一价格折算 · 从省到贵排列 · 条形 = 每题费用，从 0 画起

序号	框架	每题费用	答对率
01	Pi	¥0.14	85.1%
02	OpenCode	¥0.15	81.3%
03	**Expert Work**	**¥0.18**	**84.3%**
04	DeepSeek Harness	¥0.20	78.3%
05	Cline	¥0.26	76.6%

04 · 可信度

为什么可信

测评集权威

中国人民大学、清华大学与智谱 AI 发布

论文被人工智能顶级会议 NeurIPS 2024 收录；题目和评分程序全部开源，任何人都可复查。

题目来自真实求助

取自 Excel 论坛上用户的真实提问，表格里有多张表、不规范的表头等真实情况。

专家逐题核验版

2025 年底推出 400 道专家逐题核验的版本，本次用其中前 50 道。

机器逐格判分

对照标准答案逐格比对，只看交出来的表格，不靠人工主观判断。

测评方式公平

同一个模型 · 同一批题

5 家都用 DeepSeek V4.1 Flash，做同样的 50 道题，题目说明是同一段话。

同一个裁判

沿用 HarnessRouter 公开的评分方式和计分规则：联网或到工作区以外找答案的题，不计分。

不开小灶

最简配置：只有读写文件、运行脚本等基础工具，不接知识库，不针对题目做调整。

> **2 轮平均，不挑最好的一次**
>
> 连跑 2 轮：84.8%、83.7%；别家是 HarnessRouter 公布的 1 轮成绩。

数据来源：SpreadsheetBench 论文（arXiv 2406.14991，NeurIPS 2024）；题目与评分程序 github.com/RUCKBReasoning/SpreadsheetBench（Verified 版，400 题）；另外 4 家的成绩和用量取自 HarnessRouter 公开的测评记录 github.com/HarnessRouter/harnessrouter/blob/main/docs/benchmark.md（2026 年 9 月 18–19 日）；OpenClaw 基于 Pi 开发，见 OpenClaw 官方文档 docs.openclaw.ai/pi。

Expert Work 的成绩：2026 年 10 月 16 日，测试环境，2 轮，按 HarnessRouter 同一套题目说明、评分程序和计分规则在本地打分。50 题中有 2 题官方评分程序自身判不了，5 家都不计；联网或到工作区以外查找的题不计分（Expert Work 两轮分别 2、5 道，Pi 1 道，DeepSeek Harness 2 道，Cline 1 道，OpenCode 0 道）。费用含全部 50 道题，按同一价格折算（每百万 token：输入 2 元、缓存 0.04 元、输出 8 元）。