EXPERT WORK · 测评报告 · 2026.10

Expert Work

同一个模型，与 OpenAI、Anthropic 同处第一梯队

测评集 Harness-Bench（北京大学与 Qiyuan Tech 发布）· 257 道真实工作任务 · 8 家统一使用 DeepSeek V4 Pro 模型

68.4
综合得分 · 4 轮平均

< 1.3 分
前 4 名之间的差距，在误差之内

¥1.3
每道题的模型费用，主流水平

RANKING · 8 家同题同模型

综合得分排名：前 4 名属于同一梯队

得分 = 257 道题的平均分（满分 100）· Expert Work 为 4 轮平均（69.7 / 68.4 / 66.5 / 69.2），其他 7 家为官方公布的 1 轮成绩 · 条形从 60 分画起

排名	框架	得分
1	**Codex** OpenAI	69.25
2	**Expert Work** 4 轮平均	68.44
3	**OpenCode**	68.19
4	**Claude Code** Anthropic	68.01
5	Hermes	66.66
6	Goose	65.41
7	Nanobot	64.92
8	OpenClaw	63.10

蓝色竖条 = 第一梯队 · 橙色 = Expert Work

01 · 意义

这对 Expert Work 意味着什么

同档

自研执行层，能力不吃亏

对手是 OpenAI、Anthropic 的官方框架。自研换来的可控与合规（客户数据隔离、全程留痕），没有拿能力做交换。

0 次故障

大规模运行稳定

4 轮共 1,028 道题次，最多 8 个任务同时跑，平台没有一次崩溃或超时。

1 天

测评驱动的快速改进

发现 5 处平台改进点，1 天内全部完成优化并上线测试环境；优化后失败题清零，见下方「优化之后」。

02 · 技术可解释性

Expert Work 做对了什么

逐题对照 8 家的评分明细和执行过程后，有数据支撑的三点

模型一次写得太长，平台会自动补救，任务不中断

回答超出长度上限时，平台作废那半截、提示模型拆小重做。同样的情况，OpenCode、Goose、OpenClaw 直接停在半截，这道题得 0 分。

32 / 41
4 轮撞上限 41 次，救回 32 次

交付说明更完整

"交接说明"类评分项的通过率，比 Codex、OpenCode、Goose、Nanobot 高 4–6 个百分点。

64%
对方 57–60%

不半途而废

1,028 次运行，没有一次因为格式出错而中断，也没有一次做两三步就收工。同一道题上，Goose、OpenCode 都因格式出错中断过。

0 次
中途放弃 / 格式出错中断

第 1 条有执行记录直接对应；第 2、3 条是观察到的行为差异，尚未单独做对照实验。

03 · 分类对比

不偏科：5 个主要类别都高于 7 家平均

Expert Work 为 4 轮平均 · 名次为在 8 家中的位置 · 网页开发只有 1 道题，只计入总分

类别（题数）	Expert Work	7 家平均	该类第 1	名次
软件开发 74	56.7	55.1	OpenCode 60.8	3
业务运营 66	75.2	73.8	Codex 79.2	4
系统运维 61	72.0	69.3	Codex 74.6	2
研究分析 40	71.5	69.8	Nanobot 73.1	4
内容生产 15	74.7	70.5	Hermes 74.9	2
网页开发 1	60.0	68.6	多家 80.0	仅 1 题

04 · 成本

每道题约 1.3 元，处于主流水平

按 DeepSeek 官方价格计 · 从省到贵排列 · 条形 = 每题费用，从 0 画起

序号	框架	每题费用	得分
01	Codex	¥0.83	69.25
02	OpenCode	¥0.93	68.19
03	OpenClaw	¥1.22	63.10
04	Claude Code	¥1.24	68.01
05	**Expert Work**	¥1.26	68.44
06	Hermes	¥1.31	66.66
07	Nanobot	¥1.69	64.92
08	Goose	¥2.13	65.41

05 · 指标

每个指标是什么意思

Expert Work 的数字为 4 轮平均

指标	Expert Work	含义	其他 7 家
综合得分	68.4	每道题按做到了多少项要求给 0–1 分，257 道取平均再乘 100，相当于考试的平均分	63.1–69.3
满分题	74 道	每项要求都做到的题	58–70 道
零分题	18 道	完全没做成、或触犯安全规则被判零的题	16–38 道
高分题	141 道	得 0.8 分以上、关键要求全部达成的题	132–149 道

06 · 可信度

为什么可信

测评集权威

北京大学与 Qiyuan Tech 发布
2026 年发表论文；题目和评分程序全部开源，任何人都可复查。

专门比较"智能体框架"
同一个模型换不同框架去做同一批工作，比的正是 Expert Work 自研的这一层。

274 道真实工作任务，1,408 个评分点
覆盖 6 大类；机器对照隐藏的标准答案打分，只看交付结果，不靠人工主观判断。

7 家框架的逐题成绩公开
每道题都可以和 Claude Code、Codex 等逐一对照。

测评方式公平

同一个模型 · 同一批题
都用 DeepSeek V4 Pro，关键设置与官方一致；题目原文照发，8 家按同样 257 道计分。

同一个裁判
用官方开源的评分程序，按官方当时的评分口径打分。

不开小灶
最简配置，不开记忆、知识库，不针对题目做调整。

4 轮平均，不挑最好的一次
连跑 4 轮：69.7、68.4、66.5、69.2。只跑一次，运气就能差 3 分；别家是官方 1 轮成绩。

07 · 下一步

下一步

01 **优化进入生产**
这次测评中完成的 5 处优化，随下一次发布进入生产环境，客户直接受益。

02 **建立自有业务测评**
公开测评考的是通用能力。下一步用客户真实场景的任务，衡量对业务真正有用的能力。

03 **定期复测**
每次重要更新后重跑这套公开测评，持续跟踪 Expert Work 与主流框架的差距。

EXPERT WORK · 优化后效果 · 2026.10

优化之后

失败题从每轮 2–5 道降到 0 道

测评中发现的改进点当天完成优化、上线测试环境后，用同一套 257 道题、同一个模型、同样的评分口径再跑一轮

0 道
失败题，优化前每轮 2–5 道

11 / 11
模型写超长的情况全部救回，优化前 30 次只救回 21 次

¥1.25
每道题的模型费用，优化前 ¥1.26，没有增加

优化之后 · 改了什么

两处优化

01 **模型一次写得太长时，最多补救 3 次**
原来只补救 1 次，再写超长就整道题失败；现在每一步最多补救 3 次，次数和 Claude Code 一样。

02 **让模型看得到自己之前的思考**
按 DeepSeek 官方要求，把模型前面每一步的思考过程一并发回，它不必每一步都从头想起。

数据来源：Harness-Bench 论文（arXiv 2605.27922）；题目与评分程序 github.com/Qihoo360/harness-bench；7 家成绩取自官方公开的逐题数据，7 家费用取自论文公布的每题平均值（274 道题，按同一价格折算成人民币）。

Expert Work 的成绩：2026 年 10 月 17 日，测试环境，4 轮，用官方评分程序在本地打分，评分口径与官方当时一致。「优化之后」部分：优化前为前 3 轮，优化后为第 4 轮。官方共 274 道通用题，其中 17 道依赖 Expert Work 的接入方式无法原样复现的条件，8 家都不计入。